

孙锋

中共党员 · 15818521182 · 1075079562@qq.com · GitHub @d-sun-cs

教育背景

哈尔滨工业大学（深圳） | 计算机科学与技术 | 学硕在读 2024.9 - 至今

- 绩点 3.657/4 | 研究方向：高性能计算、并行计算 | 一篇 IPDPS 2026 (CCF B / CORE A) 论文录用

哈尔滨工业大学（深圳） | 计算机科学与技术 | 学士 2020.9 - 2024.6

- 学分绩 94.7/100 | 排名 10/527(前 1.9%) | 哈尔滨工业大学优秀团员/学生标兵 | 哈尔滨工业大学优秀毕业生
- 2021 和 2023 年国家奖学金 | 计算机系统竞赛国家级一等奖 | 数学建模竞赛国家级二等奖 | 华为智能基座奖学金

技术能力

- CPU 编程: 熟悉 C/C++、SIMD、OpenMP、MPI, 了解 Socket、SPDK
- GPU 编程: 熟悉 CUDA, 了解 wmma/mma、cuBLAS、CUTLASS、NCU Profiling
- 推理 (训练): 了解 TensorRT、vLLM、SGLang、Triton Inference Server、verl

实习经历

天王星量化深圳研究院 2024.06 - 2024.09

推理框架优化项目 | C++ 语言 | 高性能计算开发实习生

- 背景: 公司专用量化模型的推理框架有待进一步优化, 并需要完善文档以支撑后续迭代。
- 任务: 为推理框架撰写技术文档, 学习开源推理框架 (ONNX Runtime), 进一步探索计算图的推理加速方案。
- 工作: ①模块化撰写项目文档, 了解框架代码基本情况; ②提出“懒执行”优化策略, 保存输入节点最大子树以实现增量执行; ③设计线程池并发执行算子, 为张量绑定条件变量, 解决 DAG 同步问题。
- 结果: 测试场景下, “懒执行”提速约 20%, 线程池并发推理在 4-8 核 CPU 下提速约 120%。

项目经历

多模态理解/生成模型的低比特强化学习训练稳定性优化 2026.01 - 2026.06

科研项目 | Python / CUDA | verl、DanceGRPO 框架

- 背景: RL 中 rollout 耗时占比大, 低精度推理可加速采样, 但训推不匹配会使 ppo_ratio 偏置、reward 崩溃。
- 任务: 定位并消除训推不匹配引发的 LLM 及扩散模型 GRPO 训练崩溃, 实现低精度 rollout 加速。
- 工作: ①在 verl 中实现截断采样与拒绝采样, 补充 PPO ratio 均值归一化与梯度裁剪, 校正训练与 rollout 的 log-prob 偏移; ②对 Diffusion GRPO 推导高斯 log-ratio 的 Δ 分解, 定位 reward 崩溃源于 $A \cdot \Delta$ 精度差正反馈漂移, 提出零额外耗时的 Δ -debias (居中 ratio) 与 Δ -stopgradient (STE 修正梯度方向); ③实现 MXFP4 在线 Hadamard 旋转量化 (Qutlass kernel) 与 MXFP4 QAT 假量化, 将离群值能量扩散到块内、抑制 block 量化误差。
- 结果: LLM/多模态 GRPO 的 MXFP8 配置 reward 接近 BF16 基线; MXFP4 推理经旋转将 GSM8K 准确率损失由 45% 收窄至 9%。

FastTT: 移位异或纠删码高性能优化与 Ceph 集成 2025.02 - 2025.11

IPDPS 2026 录用论文 | 硕士毕业设计 | C++ 语言

- 背景: 移位异或纠删码 (Two-tone) 理论复杂度低, 但现有实现存在功能性差和内存访问瓶颈的问题。
- 任务: 设计高性能纠删码库 FastTT, 将其集成至分布式存储系统 Ceph, 并解决工程落地的性能瓶颈。
- 工作: ①提出窗口划分与相邻合并访问技术, 增强局部性并消除冗余读写; ②设计“纠删-校验映射”统一解码流程, 结合遍历模式选择策略加速单块故障恢复; ③完善算法编解码功能, 作为纠删码插件集成至 Ceph。
- 结果: 编解码吞吐量相比于 Ceph 中 SOTA 库 ISA-L 和学术 SOTA 库 Cerasure 都有平均约 30% 的提升。

面向新型 GPU 架构的稀疏矩阵乘法 (SpMM) 优化 2023.11 - 2024.05

本科毕业设计 | CUDA C++ 语言

- 背景: 内存访问是 SpMM 的性能瓶颈, Ampere 架构新增共享内存异步传输新特性, 可用于缓解内存瓶颈。
- 任务: 利用从全局内存到共享内存异步数据拷贝的新特性, 通过流水线数据预取优化 SpMM 算法。
- 工作: 用 NCU 分析性能瓶颈, 用新特性改进 GCOOSpDM 算法, 并实现基于 CSC 格式提高内存复用的算法。
- 结果: 应用新特性的算法在小矩阵和高稀疏度的情况下速度比 cuBLAS 和 cuSPARSE 平均提升 140%。

基于 SPDK 实现 Linux 用户态 IO 多路径软件 2023.03 - 2023.08

全国大学生计算机系统能力大赛 | 国家级一等奖 | 参赛队长 | C 语言

- 背景: SPDK 是新型用户态高性能存储驱动, 但是其绕过了 Linux 内核, 无法使用内核多路径功能。
- 任务: 模仿内核多路径功能, 基于 SPDK 开发用户态多路径软件, 用于高效稳定的虚拟化存储网络。
- 工作: 用动态链接库添加用户态多路径, 实现故障处理和负载均衡等功能, 编写项目文档。
- 结果: 存储网络中, 添加多路径的 SPDK 在稳定性和性能方面优于单路径和内核多路径。

课余活动

- 学院第四届学生会主席 (深圳市优秀学生会)、校艺术团电声部乐队键盘手 (晚会表演、合唱团伴奏)
- 2023 年腾讯校园大使 (优秀校园大使)、中兴通讯校园大使 (中兴捧月 164% 超额完成任务)